

10 proyectos open source para un stack de IA local

Motores, interfaces y utilidades para ejecutar modelos sin depender de APIs externas.

1 Por qué montar IA en local

Ejecutar los modelos en infraestructura propia da **más control**, **más privacidad** y **menos dependencia** de proveedores en la nube.

- **Soberanía del dato:** la información sensible no sale de la organización.
- **Coste predecible:** sin facturación por token; se paga el hardware.
- **Funcionamiento offline** y libertad para elegir, cuantizar o ajustar modelos.

2 Motores de inferencia

01 · Ollama

Descarga y ejecuta modelos con un solo comando. La vía más rápida para empezar.

★ 80.5k Go LLMs

02 · llama.cpp

Inferencia eficiente en CPU y GPU; referencia para modelos cuantizados.

★ 68.1k C++ LLMs

04 · vLLM

Servidor de alto rendimiento y alta concurrencia, pensado para producción.

★ 46.8k Python Serving

10 · MLX-LM

Ejecución y ajuste de modelos optimizados para chips Apple Silicon.

★ 24.8k Python Apple Silicon

3 Interfaces y APIs

03 · Open WebUI

Interfaz de chat autoalojada, al estilo ChatGPT, sencilla y completa.

★ 56.2k Python Interfaz

05 · LocalAI

API compatible con OpenAI para modelos locales: texto, imagen, audio...

★ 32.4k Go API

4 Multimodal, ajuste fino e infraestructura

06 · ComfyUI

Generación de imagen y vídeo mediante flujos de trabajo por nodos.

★ 53.7k

Python

Imagen / Vídeo

07 · whisper.cpp

Transcripción de voz a texto rápida y precisa, sin nube.

★ 37.9k

C++

Audio

08 · Unsloth

Fine-tuning eficiente, viable en GPUs de gama asequible.

★ 34.1k

Python

Fine-tuning

09 · exo

Agrupar varios dispositivos en un único clúster de inferencia.

★ 25.6k

Rust

Infraestructura

5 Cómo encajan: un stack típico

Modelo (GGUF / HF) › **Motor** (Ollama · llama.cpp · vLLM) › **API** compatible OpenAI › **Interfaz** (Open WebUI)

Mapa por capas

stack-ia-local/		
└─ interfaz/	Open WebUI	chat autoalojado
└─ api/	LocalAI · Ollama	endpoints tipo OpenAI
└─ inferencia/	llama.cpp · vLLM · MLX-LM	
└─ multimodal/	ComfyUI · whisper.cpp	imagen, vídeo, audio
└─ entrenamiento/	Unsloth	fine-tuning
└─ infraestructura/	exo	clúster distribuido

En resumen · Con **Ollama o llama.cpp** como motor y **Open WebUI** como interfaz ya se tiene un asistente privado funcional; vLLM, ComfyUI, whisper.cpp, Unsloth y exo amplían el stack hacia **producción, multimodalidad, ajuste fino y escalado**.



UNIVERSIDAD
DE
CÓRDOBA

Aula de Transformación Digital FIWARE · Universidad de Córdoba

Fuente: infografía «10 proyectos open source para tu stack de IA local» (Growth4U / Martín Fila). Estrellas de GitHub según dicha infografía; pueden haber variado.