

MEMORIA TÉCNICA · CITRIDATA

Ingesta del modelo de rendimiento de cítricos en la plataforma FIWARE

Descripción del proceso seguido, carpeta a carpeta, desde el Excel original hasta los ficheros exportados por el DataHUB, con la justificación de cada paso y las observaciones detectadas al comparar la entrada con la salida.

Autor: José Checa Claudel · Aula de Transformación Digital FIWARE (ATD FIWARE), Universidad de Córdoba



En una frase

La secuencia resuelve tres problemas distintos, cada uno en su carpeta: **entender** los datos de origen (1), **estandarizarlos** conforme a Smart Data Models para que sean interoperables fuera de este proyecto (2) y **adaptarlos** al esquema concreto que admite hoy la plataforma FIWARE de la UCO (3). La carpeta 4 es la verificación: lo que la plataforma devuelve una vez ingerido, en una versión completa y otra seudonimizada.

Trazabilidad: los 262 registros del Excel llegan como 262 entidades a cada etapa; los identificadores de la exportación coinciden uno a uno con los del fichero importado.

Cifras del conjunto de datos

Magnitud	Valor
Registros (filas del Excel, hoja «Selección calidad 1»)	262 (263 filas con cabecera) × 53 columnas
Campañas	9, de 2016-2017 a 2024-2025 (25-30 registros por campaña)
Fechas de recolección	del 17/10/2016 al 12/05/2025
Variedades	8 (Salustiana 143, Navelina 74, Cadenera 12, Navel Foyo 12, Fukumoto 9, Star Ruby 7, Navel 4, Barberina 1)
Fincas / productores distintos	25 / 24
Parcelas por registro	1 referencia catastral en 217 registros, 2 en 35 y 4 en 10

1 Carpeta «1.- Originales»: los datos de partida

Qué contiene. Tres ficheros que representan el mismo conjunto de datos en tres formas:

Fichero	Papel en el proceso
1.- Modelo_rendimiento_210726_V4_variadad_historico.xlsx	Tabla fuente del modelo de predicción de rendimiento por variedad (versión V4, 21/07/2026), con histórico de rendimientos.
2.- Variables modelo rendimiento 21072026.docx	Diccionario de datos: descripción en español de cada cabecera del Excel (unidades y significado).
3.- Modelo_rendimiento_..._historico.json	Volcado del Excel a JSON (array de 262 objetos con las cabeceras originales como claves).

Por qué este paso. El Excel es el formato en que trabaja el equipo agronómico, pero no es procesable de forma fiable por la plataforma. El JSON conserva exactamente las mismas columnas y valores y sirve de entrada neutra, legible por máquina, para la conversión; el documento de variables aporta la semántica (unidades, definición, variables objetivo) sin la cual no se puede construir un modelo de datos correcto.

Bloques de información de cada registro

Bloque	Columnas del Excel
Identificación y campaña	Año, Campaña, Proveedor, Descripcion_cultivo, Variedad_tipo, Variedad_familia, Fecha, DOY, DOY_c
Parcela y finca	Parc_catastral, Nombre_finca, Superficie_parcela, Perim_m, Fecha_plan, Coef_regad, Uso
Producción y rendimiento	Produccion/Rendimiento_parcela, Superficie/Produccion/Rendimiento_variedad (variables objetivo)
Topografía	pte_media, Ori_nor/sur/este/oeste, O_Dominante, Pte_0_5 ... Pte_30_max
Agroclima de la campaña	Precipitacion, ETo, ETc, Mean/Max/Min_Temp, Mean_RH, Radiation_MJ, CWD, PCWD, GDD, T35, Frost_risk
Teledetección (medias)	EVI2, MSI, NDMI, NDRE, NDVI, NIRv
Histórico de rendimiento	RV_t1, RV_t2, RV_mean_hist (vacíos en las primeras campañas, por construcción)

Incidencias detectadas en el origen

Al contrastar el Excel con su diccionario se detectaron cuatro puntos que condicionaron el paso 2:

- La cabecera real es **Descripcion_cultivo**, mientras que el documento la llama «Cultivo_finca».
- **Fecha_plan**, **Uso** y **O_Dominante** no están descritas en el documento de variables; su significado se infirió (año de plantación, código de uso SIGPAC «CI», orientación dominante) y queda marcado «a confirmar».
- En las **25 filas de la campaña 2024-2025** las columnas están desplazadas: O_Dominante contiene «CI», Uso contiene valores numéricos residuales (p. ej. «-0,002») y Nombre_finca está vacío.
- Las unidades de producción se describen como «kg o t, según la base de datos»; por la magnitud de los valores y el rendimiento en t/ha se fijaron en toneladas.

2 Carpeta «2.- dataModel.CitriData»: el modelo Smart Data Models

Qué es. Un paquete de contribución al programa *Smart Data Models* (FIWARE Foundation / TM Forum / IUDX) que define una nueva entidad, **CitrusYieldRecord**, dentro de un nuevo subject **dataModel.CitriData** (versión 0.1.0, licencia CC BY 4.0). Cada entidad representa el registro anual de cosecha de una parcela y variedad, junto con las variables topográficas, agroclimáticas, de teledetección e históricas que alimentan el modelo de predicción.

Por qué este paso. Ingerir las columnas tal cual habría producido un conjunto de datos útil sólo para este proyecto. Modelarlo según SDM aporta nombres de atributos normalizados en inglés, tipos y rangos validables mediante JSON Schema, unidades UN/CEFACT, un contexto JSON-LD con URIs estables y relaciones explícitas con las entidades existentes de *dataModel.Agrifood* (AgriParcel, AgriFarm, AgriCrop). Eso hace los datos reutilizables por cualquier otro Context Broker NGSI-LD y por el espacio de datos agroalimentario.

Estructura del paquete

Elemento	Función
context.jsonld	Contexto JSON-LD del subject: asocia cada atributo a https://smartdatamodels.org/dataModel.CitriData/...
model.yaml, schema.json	Definición del modelo (x-ngsi, descripciones) y JSON Schema validable; hereda GSMA-Commons y Location-Commons.
doc/spec.md, README.md, notes.yaml	Especificación legible, atributos, relaciones, obligatorios y patrón de identificador.
MAPPING_ES.md	Tabla de correspondencia columna Excel → atributo SDM, con tipo, unidad y descripción en español.
examples/	Ejemplos keyValues y normalizado, en NGSI v2 (.json) y NGSI-LD (.jsonld), con datos ficticios.
code/attributes.py, convert.py	Tabla única de atributos y conversor reproducible Excel/JSON → entidades.
data/	Resultado de la conversión: 262 entidades keyValues y normalizadas, e informe de reparaciones.
ADOPTERS.yaml, LICENSE.md	Adoptante (ATD FIWARE - UCO, proyecto CitriData) y licencia.

Decisiones de modelado

- **Nombres:** las 53 columnas pasan a atributos camelCase en inglés (Rendimiento_variedad → varietyYield, CWD → climaticWaterDeficit, RV_t1 → previousSeasonVarietyYield).
- **Tipos y unidades:** integer/number/string con mínimos y máximos cuando procede (p. ej. DOY 1-366) y unitCode UN/CEFACT en la forma normalizada (tonelada, hectárea, mm, °C, MJ/m², %).
- **Valores controlados:** la orientación NORTE/SUR/ESTE/OESTE se normaliza al enumerado north/south/east/west; la fecha pasa a format: date.
- **Referencias catastrales:** la cadena «14036-38-20-2;14036-38-34-1;» se convierte en un array cadastralReference.
- **Relaciones:** hasAgriParcel (una por referencia catastral), hasAgriFarm (desde Nombre_finca) y hasAgriCrop (desde la variedad), para enlazar con dataModel.Agrifood.
- **Identificador único:** urn:ngsi-ld:CitrusYieldRecord:<campaña>:<refCat1>[_<refCat2>...]:<variedad>; el conversor comprueba que no hay duplicados.
- **Obligatorios:** id, type, season, variety, harvestDate y hasAgriParcel.

- **Datos personales:** producerName se documenta explícitamente como posible dato personal (RGPD).

El conversor y la reparación de datos

convert.py lee el Excel o el JSON de la carpeta 1 y genera tres ficheros en data/:

```
python code/convert.py "1.- Originales/3.- Modelo_..._historico.json" data/
-> CitrusYieldRecord_keyvalues.jsonld   NGSI-LD keyValues (array, con @context)
-> CitrusYieldRecord_normalized.jsonld   NGSI-LD normalizado (listo para /entityOperations/upsert)
-> conversion_report.json               262 registros, 25 filas reparadas
```

Antes de convertir aplica una regla de reparación para las 25 filas de 2024-2025 con columnas desplazadas: como finca, uso y orientación son atributos estáticos de la parcela, se restauran desde otra campaña de la misma referencia catastral, y el valor numérico espurio de «Uso» se registra en el informe. Las 25 filas tuvieron campaña de referencia, así que ninguna quedó sin orientación. Los valores nulos (p. ej. RV_t1 en la primera campaña) se omiten del atributo en lugar de enviarse como null.

3

Carpeta «3.- JSON.SDM.Data»: adaptación a la plataforma

Qué contiene. Dos ficheros: el esquema que admite hoy la plataforma FIWARE de la UCO para el tipo **citri.yield.record** y el fichero de datos preparado para importarse con ese esquema.

Fichero	Contenido
1.- citri.yield.record-schema_plataforma.json	Esquema del portal (portal.atdfiware.uco.es/api/schema/citri.yield.record/latest): 59 propiedades con tipo y etiqueta visible en español (ccoc-label), título «CITRI - Rendimiento por Variedad» y atributos mostrados por defecto (id, season, variety, farmName).
2.- toImport_CitrusYieldRecord_..._V4.json	Array de 262 entidades en formato keyValues, idénticas a las de data/CitrusYieldRecord_keyvalues.jsonld salvo por la eliminación del @context.

Por qué este paso. El modelo SDM es el estándar; la plataforma tiene su propia forma de declarar tipos de entidad. Esta carpeta es el puente entre ambos:

- El esquema de la plataforma reproduce **los mismos nombres de atributo** que el modelo SDM (57 atributos + id y type), de modo que la semántica se conserva y la correspondencia con el estándar es directa.
- Añade lo que el usuario del portal necesita: **etiquetas en español con la unidad** (p. ej. «Rendimiento de la variedad (Tn/ha)», «Evapotranspiración de referencia ETo (mm)»).
- Simplifica los tipos al repertorio de la plataforma: los enteros pasan a number, la fecha a datetime y las referencias catastrales y hasAgriParcel se declaran como array de string.
- Se usa la representación **keyValues sin @context** porque es la que acepta el importador; la forma normalizada NGSI-LD (con unitCode) queda en la carpeta 2 para la contribución SDM y para cargas directas a un Context Broker.

```
{ "id": "urn:ngsi-ld:CitrusYieldRecord:2016-2017:14036-36-13-1:NAVELINA",
  "type": "CitrusYieldRecord", "season": "2016-2017", "variety": "NAVELINA",
  "harvestDate": "2016-12-09", "cadastralReference": ["14036-36-13-1"],
  "varietyYield": 21.27665706, "dominantOrientation": "west", ...,
  "hasAgriParcel": ["urn:ngsi-ld:AgriParcel:14036-36-13-1"],
  "hasAgriCrop": "urn:ngsi-ld:AgriCrop:NAVELINA",
  "dataProvider": "ATD FIWARE - Universidad de Córdoba" }
```

Extracto de una entidad del fichero de importación (se omiten los datos del productor).

4 Carpeta «4.- DataHUB Export»: la salida de la plataforma

Qué contiene. El resultado de exportar el tipo citri.yield.record desde el DataHUB mediante una URL de descarga pública, en dos variantes:

Fichero	Contenido
1.- url_hashedNames.txt	URL pública de descarga (portal.atdfiware.uco.es/file/datahub/...json) y las dos expresiones de la consulta: md5("producerName") AS "producerNameHash" y md5("farmName") AS "farmNameHash".
2.- citri---rendimiento-variedad.json	Exportación completa: 262 registros con todos los atributos en claro.
3.- citri---rendimiento-variedad_hash.json	Exportación seudonimizada: 262 registros en los que producerName y farmName se sustituyen por su hash MD5; también se omiten fiware_service, fiware_servicepath y entity_location.

Por qué dos salidas. La exportación completa es para uso interno y verificación. Para publicar o compartir los datos (por ejemplo, en el espacio de datos o con terceros) interesa no exponer el nombre del productor, que puede ser una persona física, ni el de la finca. El MD5 mantiene un identificador estable —permite agrupar por productor o finca y cruzar campañas— sin mostrar el valor original. Se comprobó que los hashes corresponden exactamente al MD5 de los valores importados.

Qué añade o cambia la plataforma

Importado (carpeta 3)	Exportado (carpeta 4)	Comentario
id	entity_id	Mismo valor; los 262 identificadores coinciden.
type = CitrusYieldRecord	entity_type = citri.yield.record	La plataforma usa su nombre de esquema como tipo.
—	fiware_service = fs_uco, fiware_servicepath = /citridata	Tenant y ruta de servicio FIWARE donde residen los datos.
—	entity_ts, validity_ts	Marca de tiempo de la ingesta (25/09/2026, 18:27-18:28 UTC); validity_ts vacío.
—	entity_location = Point [0, 0]	Ubicación por defecto: el registro no aporta coordenadas.
harvestDate = 2016-12-09	2016-12-09T00:00:00.000Z	La fecha pasa a fecha-hora ISO 8601 (tipo datetime del esquema).
decimales (double)	precisión simple (float32)	p. ej. 476.8 → 476.79998779296875; error relativo máximo $5,9 \cdot 10^{-8}$, sin relevancia agronómica.
cadastralReference, hasAgriParcel	null + columnas *_items	Ver observaciones.

5 Observaciones de la comparación entrada/salida

Comparando registro a registro el fichero importado con la exportación completa aparecen algunos puntos que conviene revisar antes de dar el flujo por cerrado:

1. Pérdida de los atributos de tipo array. cadastralReference y hasAgriParcel llegan con valor nulo en los 262 registros, y aparecen columnas auxiliares cadastralReference_items y hasAgriParcel_items, también vacías. Parece que la plataforma separa los arrays en una estructura aparte que la exportación no está recomponiendo. Se pierde el vínculo con la parcela, que es un atributo obligatorio del modelo.

2. Pérdida del histórico de rendimiento. previousSeasonVarietyYield, twoSeasonsAgoVarietyYield y historicalMeanVarietyYield tienen valor en 224, 190 y 224 entidades importadas, pero salen nulos en todas las exportadas. Son precisamente los predictores históricos del modelo. Una hipótesis a comprobar: el conversor omite los atributos nulos y la primera entidad del fichero (campaña 2016-2017) no los contiene; si el importador infiere columnas a partir de los primeros registros, los descartaría. Enviarlos explícitamente como null en todas las entidades, o revisar el mapeo del importador, debería resolverlo.

3. Seudonimización incompleta en la salida con hash. Aunque farmName se sustituye por su MD5, el nombre de la finca sigue siendo legible en hasAgriFarm (urn:ngsi-Id:AgriFarm:<finca>) y, en buena parte de los casos, en cropDescription («variedad – finca»). Además, un MD5 sin sal sobre sólo 24 productores y 25 fincas puede revertirse por diccionario si se conoce la lista de candidatos. Si el objetivo es anonimizar frente a terceros, conviene ocultar o transformar también esos dos campos y usar un hash con sal secreta (HMAC) o identificadores opacos.

4. Otras cuestiones menores. La ubicación es [0, 0] en todos los registros: podría calcularse el centroide de la parcela a partir de la referencia catastral (SIGPAC/Catastro). Quedan por confirmar con el equipo agronómico el significado de Fecha_plan, Uso y O_Dominante y la unidad de producción, y convendría corregir en origen el desplazamiento de columnas de la campaña 2024-2025 para no depender de la regla de reparación.

Resumen de trazabilidad

Etapas	Formato	Registros	Atributos
1 · Excel / JSON original	Tabla plana, cabeceras en español	262	53 columnas
2 · Modelo SDM (data/)	NGSI-LD keyValues y normalizado, con @context	262	57 + id, type, @context
3 · Fichero de importación	keyValues sin @context	262	57 + id, type
4 · Exportación DataHUB	JSON plano con metadatos FIWARE	262	66 (63 en la versión con hash)